

LOGO ANÁLISE MACRO
(placeholder — substituir)

Índice de Tom das Atas do Copom

Calibração via LLMs em Paralelo e Baseline Léxico

[Nome do(a) autor(a)]

Análise Macro

22 de setembro de 2026

Resumo

Este paper descreve a construção de um Índice de Tom para as atas do Comitê de Política Monetária (Copom) do Banco Central do Brasil, numa escala contínua de -3 (fortemente dovish) a $+3$ (fortemente hawkish). O tom é medido de quatro formas independentes sobre o mesmo texto — três Large Language Models (LLMs) em paralelo (Gemini, Claude e OpenAI) mais um baseline léxico hawkish/dovish — e calibrado contra a variação efetiva da meta Selic decidida em cada reunião, via regressão OLS. A robustez da calibração é avaliada em três exercícios complementares (in-sample, holdout e walk-forward), e a comparação entre modelos é formalizada pelo teste de Vuong para modelos não aninhados. Este documento é gerado inteiramente por código executável — tabelas e figuras vêm de chunks que leem os dados processados pelo pipeline do projeto, nunca de números digitados à mão. Nesta versão, o pipeline já rodou contra dados reais para os quatro modelos (232^a à 281^a reunião, $n = 50$). Os três LLMs explicam a variação da Selic de forma estatisticamente significativa — Gemini ($\hat{\beta} = 0.32$, $p < 0.001$, $R^2 = 0.31$), Claude ($\hat{\beta} = 0.47$, $p < 0.001$, $R^2 = 0.34$) e OpenAI ($\hat{\beta} = 0.48$, $p < 0.001$, $R^2 = 0.25$) —, o que o baseline léxico não faz ($p = 0.95$, $R^2 \approx 0$). O teste de Vuong confirma essa diferença como robusta para os três LLMs contra o léxico ($p = 0.0008$, $p < 0.001$ e $p = 0.0063$, respectivamente), mas não encontra diferença robusta entre os três LLMs entre si (todos os pares com $p > 0.1$).

1 Introdução

A comunicação de um banco central é, ela mesma, um instrumento de política monetária: o texto de uma ata pode sinalizar a trajetória futura dos juros tanto quanto a decisão numérica anunciada na própria reunião. Um comitê que eleva os juros mas descreve um cenário de inflação em convergência confortável para a meta está comunicando algo distinto de um comitê que eleva os juros alertando para riscos altistas persistentes — mesmo que a decisão numérica, isoladamente, seja idêntica nos dois casos. Capturar esse conteúdo qualitativo de forma sistemática e replicável é o problema que este projeto ataca.

O objetivo deste trabalho é construir um **Índice de Tom** para as atas do Copom — hawkish (favorável a juros mais altos) ou dovish (favorável a juros mais baixos) — e **calibrá-lo** contra a variação da meta Selic decidida na própria reunião a que a ata se refere. A novidade metodológica central é comparar, sobre o mesmo texto e a mesma escala, quatro formas de pontuação: três LLMs de propósito geral, usados em paralelo com a mesma persona e as mesmas instruções, e um baseline léxico determinístico e sem custo de API, que serve de piso de comparação da literatura de dicionários. A pergunta que guia a Seção de Resultados não é apenas “qual modelo pontua melhor”, mas **quando** essa diferença é estatisticamente robusta — e não um artefato de qual pedaço da amostra calhou de virar o teste.

2 Revisão da Literatura

A ideia de medir o tom de um texto econômico por contagem de palavras direcionais remonta aos dicionários de análise textual em finanças, dos quais o mais influente é o de Loughran e McDonald (2011), que mostrou que listas de palavras genéricas (como o Harvard-IV, usado fora do domínio financeiro) classificam mal o tom de documentos financeiros — um termo como “liability” é neutro em contabilidade, mas negativo num dicionário de propósito geral. A lição para este projeto é a mesma que motiva o léxico hawkish/dovish construído aqui: um dicionário precisa ser adaptado ao domínio (no nosso caso, o vocabulário de política monetária do Copom), não emprestado de outro

contexto.

Para atas de bancos centrais especificamente, Apel e Grimaldi (2012) propuseram um método de contagem direcional aplicado às minutas do Riksbank (o banco central sueco), classificando sentenças como hawkish, dovish ou neutras e agregando essas contagens numa métrica de tom por reunião — o mesmo espírito da razão $(n_{\text{hawkish}} - n_{\text{dovish}})/(n_{\text{hawkish}} + n_{\text{dovish}})$ usada no baseline léxico deste projeto (Seção 3).

Sobre o efeito macroeconômico da comunicação em si — não só da decisão numérica —, Hansen e McMahon (2016) mostram, para o Federal Open Market Committee (FOMC) dos Estados Unidos, que o conteúdo textual das atas carrega informação com efeito real sobre expectativas e variáveis macroeconômicas, distinta do puro anúncio da taxa de juros. Isso sustenta a premissa deste projeto: vale a pena medir o tom textual como objeto de estudo por si, não apenas como uma reformulação da decisão já conhecida.

Por fim, comparar formalmente o ajuste de dois modelos que explicam a mesma variável dependente com regressores diferentes e não aninhados — aqui, os quatro scores de tom explicando a mesma variação da Selic — não é resolvido por uma comparação direta de R^2 . Vuong (1989) propõe um teste, baseado na razão de verossimilhança ponto a ponto dos dois modelos, exatamente para esse cenário; é o teste usado na Seção 3 para comparar os quatro modelos deste projeto par a par.

3 Metodologia e Dados

3.1 Fontes de dados

Duas fontes públicas do Banco Central do Brasil:

1. **Atas do Copom**, via API pública em `bcb.gov.br (/api/servico/sitebc/cpom/atas` para a listagem de reuniões e `/api/servico/sitebc/cpom/atas_detalhes` para o texto de cada ata), a partir da 232ª reunião.
2. **Série SGS 432** (meta Selic definida pelo Copom), via API do Sistema Gerenciador de Séries Temporais do BCB — usada para calcular a variação da Selic decidida em cada reunião.

3.2 CRISP-DM

O projeto segue as fases do CRISP-DM: Business Understanding (a pergunta da Introdução), Data Understanding e Data Preparation (coleta e limpeza das atas, Seção 4), Modeling (os quatro classificadores de tom), Evaluation (calibração OLS e os três exercícios de robustez) e Deployment (este próprio documento).

3.3 Recorte do texto e escala do tom

De cada ata, só as seções A (“Atualização da conjuntura”) e B (“Cenários e riscos”) são pontuadas — o texto é cortado antes da seção C (“Condução da política monetária”), que trata a decisão de Selic já anunciada. Isso corta o texto por volume (a seção C costuma ser tão longa quanto A+B somadas, por listar votos e formalidades) sem perder sinal analítico, e evita vaziar a própria decisão — o alvo da calibração — para dentro do texto que os LLMs leem para pontuar o tom.

A escala do tom vai de -3.0 (fortemente dovish) a $+3.0$ (fortemente hawkish), com âncoras explícitas em cada ponto inteiro, dadas às três LLMs no mesmo bloco de instruções (persona de economista especializado em política monetária do BCB), instruídas a: avaliar apenas o tom implícito no

diagnóstico e no balanço de riscos; ignorar a decisão de taxa já anunciada; focar em inflação, ancoragem de expectativas, balanço de riscos e forward guidance; usar valores intermediários em casos ambíguos; e manter consistência entre atas semelhantes.

3.4 Baseline léxico

Um léxico pequeno de propósito (20 termos hawkish e 20 dovish, frases diretas do jargão do Copom) conta ocorrências e calcula

$$\text{score}_{\text{léxico}} = 3 \times \frac{n_{\text{hawkish}} - n_{\text{dovish}}}{n_{\text{hawkish}} + n_{\text{dovish}}},$$

sempre em $[-3, 3]$ por construção. É determinístico, sem custo de API e sem cache (o cálculo é instantâneo) — o piso da literatura de dicionários contra o qual medir se os LLMs de fato agregam sinal.

3.5 Calibração e comparação entre modelos

Para cada um dos quatro modelos, uma regressão OLS simples:

$$\Delta \text{Selic}_t = \alpha + \beta \cdot \text{score}_t + \varepsilon_t.$$

A comparação entre dois modelos não aninhados (mesma variável dependente, regressores diferentes) usa o teste de Vuong (Vuong 1989): a estatística V compara a log-verossimilhança gaussiana ponto a ponto dos dois ajustes, na interseção das observações em que ambos têm score; $V \sim \mathcal{N}(0, 1)$ sob a hipótese de equivalência, e $|V| > 1.96$ ($p < 0.05$) é o critério usado aqui para chamar a diferença de estatisticamente robusta — o sinal de V diz qual dos dois modelos é favorecido.

3.6 Três exercícios de robustez

1. **In-sample:** a própria inferência OLS ($\hat{\beta}$, IC 95%, R^2).
2. **Holdout:** calibra no treino (todas as reuniões exceto as últimas seis) e mede RMSE/MAE nessas últimas seis, fora da amostra.
3. **Walk-forward** (janela expansiva, treino mínimo de 20 atas): para cada reunião a partir da 21^a, treina em tudo que veio antes e prevê só essa reunião, repetindo por toda a amostra.

O holdout sozinho é enganoso: se as últimas seis reuniões caírem, por acaso, numa janela “calma” do ciclo de juros (Selic parada ou mudando pouco), qualquer modelo — inclusive um sem sinal nenhum — erra pouco ali, porque o alvo mal se move; a comparação entre modelos no holdout reflete o regime que calhou de cair no fim da amostra, não a qualidade real do modelo. O walk-forward usa cada reunião uma única vez como teste, treinado só com o que já era conhecido até ali, e agrega o erro sobre dezenas de previsões espalhadas por vários regimes — nenhum trecho isolado de calmaria ou turbulência domina o resultado sozinho.

4 Implementação

Esta seção documenta o pipeline real do projeto — os chunks abaixo têm `eval: false` (não são executados na renderização deste paper: dependem de rede e de chaves de API pagas) e mostram o código efetivamente usado, com comentários.

4.1 Coleta das atas

```
from coleta.atas_copom import coletar_atas, extrair_secoes_a_b

# Coleta a partir da 232ª reunião: baixa a lista de reuniões, o HTML de
# cada ata, limpa com BeautifulSoup (remove script/style/sup e notas de
# rodapé) e empacota como Document (langchain) com metadata
# {"nro_reuniao": ..., "data": ...}. Usa requests.Session com retry e
# backoff exponencial.
atas = coletar_atas()

# Recorta cada ata para as seções A e B, descartando a decisão já
# anunciada (seção C em diante) - ver Seção 4.3.
atas_recortadas = [
    (ata.metadata["nro_reuniao"], extrair_secoes_a_b(ata.page_content))
    for ata in atas
]
```

4.2 Pontuação por LLM (saída estruturada, sem parsing de texto)

```
from pydantic import BaseModel, Field

class TomAta(BaseModel):
    """Nota de tom (hawkish/dovish) de uma ata do Copom."""

    score: float = Field(
        ...,
        description=(
            "Nota de tom da ata numa escala contínua de -3.0 a +3.0: "
            "negativo = dovish, positivo = hawkish, zero = neutro."
        ),
    )
    # Sem ge/le proposital: um score do LLM levemente fora do intervalo
    # é aceito e depois clipado no loop, em vez de rejeitado na validação.

# As três chamadas usam o MESMO schema (TomAta) e o MESMO bloco de
# instruções (INSTRUcoes_SISTEMA), para que a comparação entre modelos
# isole a variável "modelo", não a variável "instrução".

# Gemini (gemini-flash-lite-latest, temperature=0):
modelo_gemini = ChatGoogleGenerativeAI(model="gemini-flash-lite-latest", temperature=0)
resultado = modelo_gemini.with_structured_output(TomAta).invoke(
    [("system", INSTRUcoes_SISTEMA), ("human", texto_secoes_a_b)]
)

# Claude (claude-haiku-4-5, temperature=0) - instruções como SystemMessage
# com cache_control "ephemeral": ativa o prompt caching nativo da
# Anthropic, já que esse bloco é idêntico em toda ata.
```

```

mensagem_sistema = SystemMessage(content=[
    {"type": "text", "text": INSTRUcoes_SISTEMA, "cache_control": {"type": "ephemeral"}}
])
modelo_claude = ChatAnthropic(model="claude-haiku-4-5", temperature=0)
resultado = modelo_claude.with_structured_output(TomAta).invoke(
    [mensagem_sistema, HumanMessage(content=texto_secoes_a_b)]
)

# OpenAI (gpt-4.1-mini, temperature=0) - tool calling nativo via
# with_structured_output, sem cache_control explícito (a OpenAI cacheia
# automaticamente do lado do servidor).
modelo_openai = ChatOpenAI(model="gpt-4.1-mini", temperature=0)
resultado = modelo_openai.with_structured_output(TomAta).invoke(
    [("system", INSTRUcoes_SISTEMA), ("human", texto_secoes_a_b)]
)

```

Cada loop de pontuação mantém um cache incremental em CSV (`scores_<provedor>_cache.csv`, colunas `nro_reuniao`, `data`, `score`): atas já pontuadas não geram nova chamada de API; erros são registrados sem derrubar as demais; o CSV só é regravado se houve score novo; e cada chamada usa `with_retry` (backoff exponencial com jitter, até 6 tentativas) sobre os erros transitórios do respectivo provedor.

4.3 Calibração e robustez

```

import statsmodels.api as sm

# Uma regressão por modelo: variacao_selic ~ score.
x = sm.add_constant(tabela_final[["score_gemini"]])
resultado_ols = sm.OLS(tabela_final["variacao_selic"], x).fit()

# Teste de Vuong entre dois modelos, na interseção das observações
# não-nulas de ambos (ver Seção 3.5).
estatistica_v, p_valor = teste_vuong(tabela_final, "score_gemini", "score_claude", ...)

# Walk-forward: para cada reunião a partir da 21ª, treina em tudo que
# veio antes e prevê só essa.
for t in range(20, n):
    alpha, beta = ajustar_ols(score[:t], y[:t])
    previsao = alpha + beta * score[t]

```

5 Resultados

5.1 Exercício 1 — In-sample

Tabela 1: Calibração OLS por modelo (in-sample)

Modelo	n	$\hat{\alpha}$	$\hat{\beta}$	$EP(\hat{\beta})$	t	p -valor	IC 95% ($\hat{\beta}$)	R^2	R^2 aj.
Gemini	50	-0.162	0.325	0.071	4.60	0.0000	[0.18, 0.47]	0.306	0.291
Claude	50	-0.337	0.472	0.094	5.03	0.0000	[0.28, 0.66]	0.345	0.331
OpenAI	50	-0.429	0.481	0.119	4.04	0.0002	[0.24, 0.72]	0.254	0.238
Léxico (baseline)	50	0.228	0.002	0.040	0.06	0.9510	[-0.08, 0.08]	0.000	-0.021

Erros-padrão de OLS clássico (não robustos a heterocedasticidade ou autocorrelação — ver Próximos Passos). IC = intervalo de confiança.

5.2 Comparações par a par (teste de Vuong)

Tabela 2: Comparações par a par entre modelos (teste de Vuong, 1989)

Modelo A	Modelo B	n	V	p -valor
Gemini	Claude	50	-0.71	0.4760
Gemini	OpenAI	50	1.05	0.2947
Gemini	Léxico (baseline)	50	3.37	0.0008
Claude	OpenAI	50	1.45	0.1479
Claude	Léxico (baseline)	50	3.98	0.0001
OpenAI	Léxico (baseline)	50	2.73	0.0063

$V > 0$ favorece o modelo A; $|V| > 1.96$ ($p < 0.05$) indica diferença estatisticamente robusta. Cada par recalibrado na interseção das observações não-nulas dos dois scores.

5.3 Exercício 2 — Holdout (últimas 6 reuniões)

Tabela 3: Robustez – holdout (calibrado no treino, medido nas últimas 6 reuniões)

Modelo	n treino	n teste	RMSE	MAE
Gemini	44	6	0.707	0.671
Claude	44	6	0.606	0.575
OpenAI	44	6	0.713	0.688
Léxico (baseline)	44	6	0.544	0.534

RMSE e MAE em p.p. de variação da Selic, calculados fora da amostra de calibração.

5.4 Exercício 3 — Walk-forward (janela expansiva)

Tabela 4: Robustez – walk-forward (janela expansiva, treino mínimo de 20 atas)

Modelo	n previsões	RMSE	MAE
Gemini	30	0.544	0.493
Claude	30	0.484	0.438
OpenAI	30	0.526	0.468
Léxico (baseline)	30	0.587	0.536

RMSE e MAE médios sobre todas as previsões fora da amostra (uma por reunião, $n_{\text{pred}} \approx 26$).

5.5 Figuras




Figura 1: Índice de Tom calibrado (p.p. de variação da Selic), por LLM.




Figura 2: Surpresa de comunicação (z-score do tom), por LLM.




Figura 3: Tom calibrado vs. variação real da Selic — comparação direta entre o que o índice de cada LLM implicaria e a decisão de fato.

6 Próximos Passos

- **Erros-padrão robustos:** a calibração atual usa OLS clássico; avaliar erros-padrão HAC (Newey-West), já que a série é temporal e pode ter autocorrelação residual.
- **Poder estatístico:** com $n = 50$ (uma observação por reunião do Copom), os testes de

significância — inclusive o de Vuong — ainda têm poder limitado; reavaliar a robustez das conclusões à medida que mais atas entrarem na amostra.

- **Revisão do léxico:** o baseline não capturou relação nenhuma com a variação da Selic ($R^2 \approx 0$, Seção~3) — o esperado de um piso de comparação, mas vale checar cobertura (quantas atas ficam com $n_h + n_d = 0$) e ajustar termos numa amostra maior.
- **Logo oficial da Análise Macro:** a capa deste documento usa um placeholder (Seção de título) — substituir por `figuras/logo_analise_macro_placeholder.png` com o arquivo real.
- **Referências bibliográficas:** os dados de Apel e Grimaldi (2012) e Hansen e McMahon (2016) foram reconstruídos de memória, sem acesso à internet para conferir volume/páginas exatos — revisar antes de submissão.

7 Conclusão

Este documento entrega o desenho metodológico completo de um Índice de Tom para as atas do Copom — quatro formas independentes de pontuação sobre o mesmo texto, calibradas contra a variação da Selic e comparadas por um teste formal de robustez estatística (Vuong), com a comparação de modelos validada em três horizontes de robustez (in-sample, holdout e walk-forward) — e a infraestrutura de código que o executa de ponta a ponta, do download da ata bruta à figura final. Com os quatro modelos já calibrados contra dados reais (50 reuniões, de 2020 a 2026, incluindo a 281ª reunião, com ata divulgada em 22/09/2026), o resultado central do projeto está de pé: os três LLMs — Gemini, Claude e OpenAI — explicam de forma estatisticamente significativa e robusta (Vuong, $p < 0.01$ em todos os pares contra o léxico) a variação da Selic, o que um dicionário simples não faz ($R^2 \approx 0$). Entre si, os três LLMs não se distinguem de forma estatisticamente robusta (Vuong, $p > 0.1$ em todos os pares) — o ganho está em usar um LLM de propósito geral em vez de um léxico fixo, não na escolha de qual LLM. O exercício de walk-forward reforça essa leitura de forma mais confiável que o holdout isolado (ver Seção~3 sobre o viés de “janela calma”): agregando erro sobre 30 previsões espalhadas por vários regimes de juros, os três LLMs têm RMSE menor que o léxico, com o Claude à frente (RMSE = 0.484), seguido por OpenAI (0.526) e Gemini (0.544), contra 0.587 do léxico — uma ordem que se inverte no holdout de seis reuniões, exatamente o sintoma do viés que motivou incluir os três exercícios de robustez em primeiro lugar. Os itens que seguem em aberto estão listados na Seção~6.

Referências

- Apel, Mikael, e Marianna Blix Grimaldi. 2012. *The Information Content of Central Bank Minutes*. Riksbank Research Paper Series. Sveriges Riksbank.
- Hansen, Stephen, e Michael McMahon. 2016. “Shocking Language: Understanding the Macroeconomic Effects of Central Bank Communication”. *Journal of International Economics* 99: S114–33.
- Loughran, Tim, e Bill McDonald. 2011. “When Is a Liability Not a Liability? Textual Analysis, Dictionaries, and 10-Ks”. *The Journal of Finance* 66 (1): 35–65.
- Vuong, Quang H. 1989. “Likelihood Ratio Tests for Model Selection and Non-Nested Hypotheses”. *Econometrica* 57 (2): 307–33.